

Diseño de una pipeline de optimización multiobjetivo basada en modelos generativos preentrenados para la generación de moléculas drug-like con afinidad proxy frente a EGFR



Universitat Oberta
de Catalunya

Kevin Luna Obando

Área 5

Máster en Ciencia de datos

Nombre del director/a de TF:
Cibrán López Álvarez

Nombre del/de la PRA:
Susana Acedo Nadal

2 de marzo de 2026



Esta obra esta sujeta a una licencia de Reconocimiento

<https://creativecommons.org/licenses/by-nc/3.0/es/>

Ficha Del Trabajo Final

Título del trabajo:	Diseño de una pipeline de optimización multiobjetivo basada en modelos generativos preentrenados para la generación de moléculas drug-like con afinidad proxy frente a EGFR
Nombre del autor/a:	Kevin Luna Obando
Nombre del director/a de TF:	Cibrán López Álvarez
Nombre del/de la PRA:	Susana Acedo Nadal
Fecha de entrega:	2 de marzo de 2026
Titulación o programa:	Máster en Ciencia de datos
Área del trabajo final:	Área 5
Idioma del trabajo:	Castellano
Palabras clave:	generative AI, drug discovery, molecular generation, multi-objective optimization, EGFR, ADMET prediction, pipeline design

Resumen del trabajo

El descubrimiento de fármacos es un proceso complejo en el que no basta con que una molécula sea activa frente a una diana terapéutica. También debe presentar buenas propiedades farmacocinéticas y ser razonablemente viable desde el punto de vista sintético. En la práctica, esto lo convierte en un problema multiobjetivo, donde hay que equilibrar varios criterios al mismo tiempo.

En los últimos años, los modelos generativos moleculares preentrenados han demostrado ser herramientas muy útiles para explorar grandes regiones del espacio químico sin necesidad de entrenar modelos desde cero. Sin embargo, generar muchas estructuras no garantiza que estas cumplan con los requisitos necesarios para convertirse en buenos candidatos a fármaco. Por ello, resulta fundamental incorporar mecanismos de evaluación y selección que permitan priorizar compuestos con un perfil equilibrado.

Este Trabajo Final de Máster propone el diseño e implementación de una pipeline computacional que combina generación molecular y evaluación multiobjetivo. En primer lugar, un modelo generativo preentrenado produce nuevas moléculas de manera no condicionada explícitamente por múltiples objetivos. A continuación, cada compuesto es evaluado según distintos criterios relevantes.

La afinidad frente al receptor EGFR se estima mediante un modelo QSAR preentrenado, que actúa como aproximación a la actividad biológica. Además, las propiedades ADMET se incorporan como filtros utilizando la herramienta Admet-AI, lo que permite descartar moléculas con perfiles farmacocinéticos desfavorables.

Finalmente, la selección de candidatos se realiza mediante un enfoque basado en dominancia de Pareto, identificando aquellas moléculas que presentan el mejor equilibrio entre afinidad estimada y propiedades ADMET adecuadas. El objetivo del trabajo no es la validación experimental de compuestos concretos, sino el desarrollo y análisis de una arquitectura de inteligencia artificial reproducible que estructure la generación y selección molecular bajo criterios multiobjetivo claros, evaluando tanto el comportamiento del frente de Pareto como la diversidad del espacio químico generado.

Abstract

Drug discovery is a complex process in which it is not enough for a molecule to be active against a therapeutic target. It must also exhibit suitable pharmacokinetic properties and be reasonably feasible from a synthetic standpoint. In practice, this makes drug discovery a multi-objective problem, where several criteria need to be balanced at the same time.

In recent years, pretrained molecular generative models have emerged as powerful tools for exploring large regions of chemical space without the need to train models from scratch. However, simply generating a large number of molecular structures does not guarantee that they meet the requirements to become promising drug candidates. Therefore, it is essential to incorporate evaluation and selection mechanisms that prioritize compounds with a balanced pharmacological profile.

This Master's Thesis proposes the design and implementation of a computational pipeline that combines molecular generation with multi-objective evaluation. First, a pretrained generative model produces novel molecules without being explicitly conditioned on multiple objectives. Each generated compound is then assessed according to several relevant criteria.

Binding affinity toward EGFR is estimated using a pretrained QSAR model, which serves as a proxy for biological activity. In addition, ADMET properties are incorporated as filtering criteria through the Admet-AI tool, allowing the removal of molecules with unfavorable pharmacokinetic profiles.

Finally, candidate selection is performed using a Pareto dominance-based approach, identifying molecules that achieve the best trade-offs between predicted affinity and suitable ADMET properties. The goal of this work is not the experimental validation of specific compounds, but the development and analysis of a reproducible artificial intelligence framework that structures molecular generation and selection under clear multi-objective principles, evaluating both the resulting Pareto front and the diversity of the generated chemical space.

Índice general

1. Introducción	9
1.1. Contexto y justificación	9
1.2. Objetivos	10
1.2.1. Objetivo principal	10
1.2.2. Objetivos específicos	11
1.3. Impacto en sostenibilidad y ético-social	11
1.4. Enfoque y método seguido	12
1.5. Planificación del trabajo	13
1.5.1. Fase 1: Definición y planificación del proyecto (M1)	13
1.5.2. Fase 2: Estado del arte (M2)	13
1.5.3. Fase 3: Diseño e implementación de la pipeline (M3)	13
1.5.4. Fase 4: Evaluación experimental y redacción final (M4)	14
1.5.5. Riesgos potenciales y planes de mitigación	14
1.6. Breve resumen de productos obtenidos	14
1.7. Breve descripción de los otros capítulos de la memoria	14
1.8. Declaración sobre el uso de inteligencia artificial generativa	14
2. Estado del arte	16
2.1. Descubrimiento de Fármacos Asistido por IA	16
2.1.1. Evolución de la computación química	16
2.2. Parámetros de Calidad Molecular en el Diseño <i>de novo</i> de Fármacos	17
2.2.1. Pequeñas moléculas como modalidad terapéutica	17
2.2.2. Propiedades drug-like y calidad molecular	18
2.2.3. EGFR como diana terapéutica	19
2.3. Representación Computacional de Moléculas y Proteínas	20
2.3.1. Representación lineal mediante SMILES	20
2.3.2. Representación basada en grafos moleculares	21
2.3.3. Representación de proteínas y sitios de unión	21
2.4. Modelado predictivo de propiedades moleculares	21
2.4.1. Modelos QSAR en descubrimiento de fármacos	22
2.4.2. Predicción computacional de propiedades ADMET	23
2.5. Modelos generativos moleculares	24
2.5.1. Generación molecular <i>de novo</i>	24
2.5.2. Modelos generativos modernos	25
2.5.3. Modelos preentrenados en química molecular	25

2.6.	Optimización multiobjetivo en diseño molecular	26
2.6.1.	Naturaleza multiobjetivo del descubrimiento de fármacos	26
2.6.2.	Estrategias de optimización molecular	26
2.6.3.	Dominancia de Pareto y soluciones no dominadas	27
2.6.4.	Métricas de evaluación multiobjetivo	28
3.	Materiales y métodos	29
3.1.	Diseño general de la metodología	29
3.2.	Materiales, entorno y librerías empleadas	30
3.3.	Preprocesado del dataset de bioactividad EGFR	31
3.3.1.	Datos de entrada y exportación desde ChEMBL	31
3.3.2.	Datos de entrada	31
3.3.3.	Canonicalización y agregación molecular	32
3.3.4.	Productos del preprocesado	32
3.4.	Fine-tuning del modelo generativo molecular	33
3.4.1.	Modelo generativo seleccionado	33
3.4.2.	Monitorización por epoch y selección del checkpoint	33
3.4.3.	Generación final y limpieza	34
3.5.	Cálculo de descriptores y filtro químico básico	34
3.6.	Modelo QSAR para estimación de actividad frente a EGFR	35
3.6.1.	Partición por scaffold	35
3.6.2.	Modelo predictivo y métricas	36
3.7.	Similitud estructural y control de novedad	36
3.8.	Integración de predicciones ADMET-AI	37
3.8.1.	Filtros ADMET duros	37
3.8.2.	Score ADMET blando	38
3.9.	Construcción de scores interpretables	38
3.10.	Pool elegible y selección mediante Pareto	39
3.10.1.	Definición del conjunto elegible	39
3.10.2.	Objetivos de Pareto	40
3.11.	Comparación con inhibidores EGFR aprobados o de referencia	40
3.12.	Exportación, trazabilidad y productos obtenidos	41
3.13.	Limitaciones metodológicas	41
4.	Resultados	42
5.	Conclusiones y trabajos futuros	43
6.	Glosario	44
7.	Bibliografía	45

Índice de figuras

1.1. Diagrama de Gantt del proyecto que muestra la planificación temporal de las tareas y fases del trabajo.	13
2.1. Comparación entre pequeñas moléculas y macromoléculas biológicas.	18
2.2. Esquema de la vía de señalización del EGFR y sus principales mutaciones en el cáncer de pulmón de células no pequeñas (NSCLC).	20
2.3. Esquema general de un modelo QSAR: a partir de datos de actividad experimental se generan predicciones y alertas estructurales.	23
2.4. Ejemplo de frente de Pareto en un problema multiobjetivo.	27
4.1. Error en función de la distancia en unidades arbitrarias.	42

Índice de cuadros

3.1. Estructura modular de los notebooks empleados en el desarrollo de la pipeline. .	30
3.2. Hiperparámetros utilizados durante el fine-tuning y la generación final.	33
3.3. Filtros fisicoquímicos básicos aplicados a las moléculas generadas.	35
3.4. Rendimiento del modelo QSAR de pIC50 basado en Random Forest y fingerprints Morgan.	36
3.5. Reglas ADMET duras aplicadas durante el scoring.	37
3.6. Pesos utilizados para el cálculo de <code>reward_score</code>	39
3.7. Reducción progresiva del conjunto molecular durante la pipeline.	41

Capítulo 1

Introducción

1.1. Contexto y justificación

El descubrimiento de nuevos compuestos terapéuticos puede formularse, en sus etapas iniciales, como un problema de exploración y priorización dentro de un espacio químico de dimensión extremadamente elevada. La cantidad de moléculas potencialmente *drug-like* es tan amplia que resulta imposible recorrerla de forma exhaustiva, lo que convierte la priorización eficiente en un componente central del proceso de investigación. En este contexto, la inteligencia artificial se ha consolidado como una herramienta clave para explorar regiones relevantes del espacio químico y proponer estructuras con propiedades compatibles con desarrollo farmacéutico [1].

Los modelos generativos moleculares preentrenados han emergido como una alternativa flexible para la generación de nuevas estructuras químicas. Estos modelos, entrenados previamente sobre grandes colecciones moleculares, permiten reutilizar representaciones aprendidas sin necesidad de entrenar sistemas desde cero para cada caso de uso específico. Evidencia reciente sugiere que los modelos preentrenados pueden capturar representaciones moleculares más informativas y generalizables en tareas de descubrimiento asistido por inteligencia artificial [2]. No obstante, la mera generación de moléculas químicamente válidas no garantiza un perfil equilibrado de propiedades farmacológicas.

El diseño molecular con fines terapéuticos constituye un problema intrínsecamente multiobjetivo. La optimización exclusiva de afinidad frente a una diana puede conducir a compuestos con perfiles ADMET desfavorables o baja viabilidad sintética. De forma análoga, priorizar únicamente propiedades de *drug-likeness* puede comprometer la señal de actividad biológica. La literatura reciente subraya la necesidad de emplear marcos formales de optimización multiobjetivo en el diseño *de novo* de fármacos, permitiendo analizar de manera explícita los compromisos entre objetivos potencialmente conflictivos [4].

En este Trabajo Final de Máster se propone el diseño y evaluación de una **pipeline computacional** que integra un modelo generativo molecular preentrenado con un esquema formal de optimización multiobjetivo basado en dominancia de Pareto. El caso de estudio se centra en el *Epidermal Growth Factor Receptor* (EGFR), una diana terapéutica ampliamente estudiada en oncología y objeto de investigaciones recientes apoyadas en aprendizaje automático [5].

A diferencia de enfoques estructurales basados en *docking* molecular, este trabajo adopta una perspectiva centrada en inteligencia artificial aplicada y modelado predictivo. La afinidad se aproxima mediante un modelo QSAR específico para EGFR previamente entrenado, que

actúa como *proxy* principal de actividad biológica. Este planteamiento permite reducir el coste computacional y centrar el análisis en la evaluación cuantitativa de estrategias de optimización.

Adicionalmente, la pipeline incorpora predicciones ADMET mediante la plataforma ADMET-AI [3], utilizadas como restricciones para descartar compuestos con perfiles farmacocinéticos o de seguridad desfavorables. Asimismo, se calculan métricas estándar como el índice QED y el *Synthetic Accessibility Score* (SA score) para caracterizar *drug-likeness* y sintetizabilidad.

De forma complementaria, se podrá analizar la similaridad estructural respecto a inhibidores conocidos de EGFR mediante fingerprints moleculares tipo Morgan (ECFP) y el coeficiente de Tanimoto, con el objetivo de estudiar si la optimización desplaza el muestreo hacia regiones químicamente próximas a compuestos activos. Esta métrica se emplea exclusivamente con fines descriptivos y de análisis del espacio químico, sin intervenir directamente en la función objetivo.

El objetivo de este trabajo no es descubrir ni validar nuevos medicamentos en el laboratorio, sino analizar si incorporar una estrategia formal de optimización a modelos de inteligencia artificial generativa mejora realmente la calidad de las moléculas que estos producen. Para ello, se compara un modelo que simplemente genera moléculas con otro que, además, intenta equilibrar varios criterios al mismo tiempo, como su posible eficacia estimada, que tengan características adecuadas para convertirse en fármacos y que sean viables en la práctica. Mediante métricas cuantitativas, se evalúa si esta optimización logra un mejor equilibrio, mayor diversidad y mayor novedad en las propuestas, aportando así evidencia metodológica sobre el impacto real de la optimización en el diseño molecular asistido por inteligencia artificial.

1.2. Objetivos

El presente trabajo tiene como finalidad principal el diseño, implementación y evaluación de una pipeline computacional para la generación de moléculas drug-like mediante modelos generativos preentrenados, integrando un esquema formal de optimización multiobjetivo. A través de este enfoque, se busca demostrar la viabilidad de estructurar el diseño molecular asistido por inteligencia artificial bajo criterios explícitos de selección y evaluación, permitiendo analizar de forma cuantitativa los compromisos entre actividad biológica estimada, propiedades farmacocinéticas y viabilidad sintética.

El trabajo se centra en la generación de moléculas con señal proxy de afinidad frente al receptor EGFR, incorporando restricciones ADMET y un procedimiento de selección basado en dominancia de Pareto, con el objetivo de evaluar si la optimización multiobjetivo mejora el perfil global de los candidatos generados respecto a un muestreo generativo no condicionado.

1.2.1. Objetivo principal

Diseñar e implementar una pipeline computacional basada en modelos generativos moleculares preentrenados e integrada con un esquema formal de optimización multiobjetivo que permita generar moléculas drug-like con señales proxy de afinidad frente a EGFR, evaluando cuantitativamente la mejora en el equilibrio entre actividad estimada, propiedades farmacocinéticas y viabilidad sintética respecto a un enfoque generativo no optimizado.

1.2.2. Objetivos específicos

Para alcanzar el objetivo principal, se plantean los siguientes objetivos específicos:

- Implementar un modelo generativo molecular preentrenado para la generación de estructuras químicas válidas representadas en formato SMILES.
- Integrar un modelo QSAR específico para EGFR como función de evaluación de afinidad *proxy*, permitiendo estimar la posible actividad biológica de las moléculas generadas.
- Incorporar predicciones de propiedades ADMET mediante la herramienta Admet-AI, estableciendo umbrales que actúen como restricciones farmacocinéticas mínimas.
- Calcular métricas de calidad molecular como el índice de *drug-likeness* (QED) y el índice de sintetizabilidad (SA score).
- Formalizar el problema como un proceso de optimización multiobjetivo considerando tres criterios principales: maximización de la afinidad *proxy* frente a EGFR, maximización del QED y minimización del SA score.
- Implementar un procedimiento de selección basado en dominancia de Pareto para identificar moléculas que representen un equilibrio adecuado entre los objetivos definidos.
- Evaluar el rendimiento del enfoque propuesto mediante métricas cuantitativas de optimización multiobjetivo, incluyendo el análisis del frente de Pareto y el cálculo del hipervolumen, así como indicadores de validez, diversidad y novedad estructural.
- Comparar los resultados obtenidos con un baseline de muestreo generativo no optimizado, analizando las diferencias en la distribución de propiedades y en la cobertura del espacio químico.

1.3. Impacto en sostenibilidad y ético-social

El presente trabajo se enmarca dentro del ámbito del descubrimiento computacional de fármacos mediante inteligencia artificial, lo que implica una serie de impactos potenciales en las dimensiones de sostenibilidad, ética y diversidad.

Impacto en sostenibilidad

Desde el punto de vista de la sostenibilidad, el uso de herramientas computacionales para el diseño molecular contribuye a reducir la necesidad de experimentación temprana en laboratorio, lo que puede disminuir el consumo de recursos materiales y energéticos asociados a procesos de síntesis y cribado experimental masivo. La implementación de pipelines de inteligencia artificial en fases iniciales del *drug discovery* permite priorizar compuestos más prometedores, optimizando recursos y reduciendo costes.

No obstante, también debe considerarse el impacto energético asociado al uso de modelos de inteligencia artificial y procesamiento computacional. Aunque en este trabajo se emplean

modelos preentrenados y no se realiza entrenamiento desde cero, es importante reconocer que el desarrollo y uso de sistemas de IA conlleva un consumo energético que forma parte del debate actual sobre sostenibilidad digital.

Impacto ético-social

La aplicación de inteligencia artificial al descubrimiento de fármacos tiene un claro potencial transformador, ya que puede acelerar la identificación de moléculas prometedoras y optimizar la fase de priorización. No obstante, es importante subrayar que los modelos utilizados en este trabajo son aproximaciones estadísticas basadas en datos previos.

Desde una perspectiva ética, los resultados obtenidos deben interpretarse como herramientas de apoyo a la decisión y no como evidencia definitiva de actividad o seguridad. La responsabilidad científica implica comunicar con claridad las limitaciones de estos modelos, su dominio de aplicabilidad y los posibles sesgos derivados de los datos con los que fueron entrenados.

1.4. Enfoque y método seguido

Existen diferentes estrategias para abordar un proyecto en el ámbito del descubrimiento computacional de fármacos. Entre ellas destacan: el desarrollo de un modelo predictivo desde cero, la adaptación y comparación de múltiples modelos existentes, o el diseño de una arquitectura que integre herramientas preexistentes dentro de una pipeline estructurada.

En este trabajo se ha optado por la estrategia de diseñar y construir una pipeline computacional que integra modelos preentrenados ya disponibles (modelo generativo molecular, modelo QSAR específico para EGFR y herramienta de predicción ADMET) bajo un marco formal de optimización multiobjetivo.

Esta decisión responde a varios motivos. En primer lugar, el objetivo principal no es desarrollar un nuevo modelo de aprendizaje automático, sino analizar cómo diferentes modelos pueden combinarse de forma coherente dentro de un sistema de toma de decisiones estructurado. En segundo lugar, el uso de modelos preentrenados permite centrar el trabajo en la arquitectura, la integración y la optimización multiobjetivo, aspectos alineados con el enfoque en inteligencia artificial aplicada e ingeniería de datos.

El método seguido se basa en una aproximación incremental:

- Generación de moléculas mediante un modelo generativo preentrenado.
- Evaluación de propiedades (afinidad *proxy*, ADMET, QED y SA score).
- Filtrado mediante restricciones ADMET.
- Aplicación de dominancia de Pareto para identificar soluciones de compromiso.
- Análisis del conjunto resultante desde una perspectiva de diversidad y distribución de propiedades.

Esta estrategia resulta apropiada para alcanzar los objetivos planteados, ya que permite formalizar el problema como un sistema multiobjetivo reproducible, centrándose en la integración metodológica y en la evaluación estructurada de resultados dentro del marco del *drug discovery* asistido por inteligencia artificial.

1.5. Planificación del trabajo

El trabajo se ha dividido en cuatro fases principales: definición y planificación, estado del arte, diseño e implementación de la *pipeline*, y finalmente evaluación de resultados y redacción de la memoria. Cada una de estas fases se corresponde con los módulos del curso (M1–M4) y culmina con la entrega de un entregable parcial.

En la planificación no se ha tenido en cuenta la defensa, ya que el trabajo estará finalizado y la fecha no puede conocerse hasta después de la entrega de la memoria.

La Figura 1.1 muestra el diagrama de Gantt del proyecto, en el que se representa la planificación temporal de las tareas, así como la duración estimada de cada fase.




Figura 1.1: Diagrama de Gantt del proyecto que muestra la planificación temporal de las tareas y fases del trabajo.

1.5.1. Fase 1: Definición y planificación del proyecto (M1)

La primera fase del proyecto se centra en la delimitación del problema, la definición de los objetivos y la planificación inicial del trabajo. En esta etapa se prepara la documentación necesaria para la entrega del primer módulo.

1.5.2. Fase 2: Estado del arte (M2)

En la segunda fase se realiza la revisión bibliográfica necesaria para fundamentar científicamente el proyecto. Esta revisión incluye el análisis de modelos generativos moleculares, técnicas de optimización multiobjetivo aplicadas al diseño de fármacos, modelos QSAR utilizados como funciones *proxy* de afinidad y herramientas de predicción ADMET.

1.5.3. Fase 3: Diseño e implementación de la pipeline (M3)

En esta fase se desarrolla la arquitectura computacional propuesta para la generación y evaluación de moléculas. Para ello se integra el modelo generativo molecular, se realizan procesos de validación y limpieza de las estructuras generadas y se incorporan los modelos predictivos utilizados para evaluar las moléculas. Finalmente, se implementa el procedimiento de optimización multiobjetivo basado en dominancia de Pareto.

1.5.4. Fase 4: Evaluación experimental y redacción final (M4)

En la última fase se llevan a cabo los experimentos finales utilizando la *pipeline* desarrollada. Los resultados obtenidos se analizan mediante métricas cuantitativas como la diversidad estructural, la novedad molecular y el análisis del frente de Pareto.

Paralelamente se redacta la memoria del Trabajo Final de Máster, incluyendo la descripción detallada de la metodología, los resultados obtenidos y las conclusiones del estudio.

1.5.5. Riesgos potenciales y planes de mitigación

Durante el desarrollo del proyecto pueden aparecer diversos riesgos que afecten al cumplimiento de la planificación prevista. Entre los principales riesgos identificados se encuentran:

Complejidad técnica en la integración de herramientas.

La integración de diferentes modelos y librerías (modelo generativo, QSAR, ADMET-AI y herramientas de análisis molecular) puede generar problemas de compatibilidad o dificultades técnicas. Como medida de mitigación, se utilizarán librerías ampliamente documentadas y se implementarán los componentes de forma modular, permitiendo aislar y resolver posibles errores de manera independiente.

Coste computacional de los experimentos.

La generación y evaluación de grandes conjuntos moleculares puede requerir un uso intensivo de recursos computacionales. Para mitigar este riesgo, se utilizarán experimentos controlados con tamaños de muestra progresivos, permitiendo validar el funcionamiento de la *pipeline* antes de escalar los experimentos.

1.6. Breve resumen de productos obtenidos

No hay que entrar en detalle: la descripción detallada se hará en el resto de capítulos.

1.7. Breve descripción de los otros capítulos de la memoria

Breve explicación de los contenidos de cada capítulo y su relación con el proyecto global.

1.8. Declaración sobre el uso de inteligencia artificial generativa

Explicación de cualquier uso que se haya hecho de herramientas de inteligencia artificial generativa (como ChatGPT, Gemini, DALL-E, u otras) durante la concepción y desarrollo de este Trabajo Final, así como la redacción de esta memoria y la preparación de la presentación. Es obligatorio especificar las herramientas concretas utilizadas, la finalidad (por ejemplo, ideación, esbozo de código, corrección gramatical, generación de imágenes, etc.), los períodos o fases del trabajo en los que se emplearon, las acciones realizadas para validar los contenidos generados

mediante IA y una valoración crítica del impacto de su uso. Se debe aclarar explícitamente qué partes del trabajo son autoría íntegra del estudiante y cuáles se han basado en inputs o resultados generados por IA, asegurando en todo momento que la responsabilidad intelectual y la validación final del contenido recaen totalmente en el estudiante, y que su uso ha sido discutido con el tutor/a del Trabajo y se ha realizado acorde a sus indicaciones.

Capítulo 2

Estado del arte

2.1. Descubrimiento de Fármacos Asistido por IA

A diferencia de la industria tecnológica, que se ha beneficiado históricamente de la Ley de Moore, el sector farmacéutico se enfrenta a la denominada Ley de Eroom, la cual describe una disminución sostenida en la productividad de la investigación y desarrollo (I+D). En la actualidad, el coste medio de llevar un fármaco al mercado supera los 2.600 millones de dólares, con tiempos de desarrollo que oscilan entre los 10 y 15 años [8].

Este proceso tradicional se caracteriza además por una elevada tasa de fracaso: más del 90–93 % de los candidatos no superan los ensayos clínicos. Las principales causas de estos fracasos son la falta de eficacia clínica y perfiles inadecuados de seguridad y propiedades ADMET (absorción, distribución, metabolismo, excreción y toxicidad), que no pueden predecirse con precisión mediante modelos animales o estudios in vitro tempranos [9].

A ello se suma la inmensidad del espacio químico, que abarca trillones de posibles moléculas con propiedades farmacológicas potenciales. El cribado experimental exhaustivo resulta inviable, ya que los métodos tradicionales de cribado de alto rendimiento (HTS) solo permiten evaluar bibliotecas físicas limitadas de compuestos, explorando así una fracción ínfima del universo químico accesible [13].

2.1.1. Evolución de la computación química

La computación química ha experimentado una transformación significativa, pasando de modelos lineales QSAR a un paradigma dominado por la inteligencia artificial, especialmente la IA generativa. Este cambio ha permitido abordar el vasto espacio químico de manera mucho más eficiente que los enfoques tradicionales. Entre las herramientas clásicas, el molecular docking permite simular la interacción entre una molécula candidata y su diana biológica, generalmente una proteína, mientras que las simulaciones de dinámica molecular permiten analizar la estabilidad de estos complejos. Asimismo, se emplean métodos computacionales para predecir propiedades clave como la solubilidad, toxicidad y comportamiento ADME de los compuestos.

La incorporación de técnicas de machine learning ha supuesto un avance significativo, ya que permite analizar grandes volúmenes de datos químicos y biológicos para identificar patrones y predecir la actividad de nuevas moléculas. Más aún, los modelos de IA generativa son capaces de diseñar estructuras químicas completamente nuevas (de novo), optimizando

simultáneamente múltiples propiedades relevantes. La irrupción del aprendizaje profundo ha ampliado considerablemente estas capacidades. Arquitecturas como las Redes Neuronales de Grafos (GNN), que representan átomos como nodos y enlaces como aristas, o las redes convolucionales (CNN), permiten aprender directamente a partir de representaciones químicas como SMILES o grafos moleculares, sin necesidad de ingeniería manual de características. Esto ha mejorado notablemente la predicción de propiedades moleculares y la modelización de interacciones fármaco-diana [8].

En consecuencia, el enfoque ha evolucionado desde la predicción de propiedades de moléculas existentes hacia el diseño de novo de nuevas entidades químicas. Mediante modelos como los Autocodificadores Variacionales (VAE), las Redes Antagónicas Generativas (GAN) y, más recientemente, los modelos de difusión, la IA permite explorar un espacio químico estimado en trillones de moléculas. Esto facilita la generación de candidatos innovadores que optimizan simultáneamente la potencia, la seguridad y la viabilidad sintética, muchos de los cuales nunca han sido sintetizados previamente [13].

2.2. Parámetros de Calidad Molecular en el Diseño *de novo* de Fármacos

2.2.1. Pequeñas moléculas como modalidad terapéutica

Las pequeñas moléculas constituyen la clase más extensa de agentes terapéuticos, representando aproximadamente el 90 % de los fármacos comercializados. Se definen principalmente por su estructura química y sus propiedades fisicoquímicas, siendo compuestos orgánicos de bajo peso molecular, generalmente inferiores a 1000 Da, formados por elementos como carbono, hidrógeno, nitrógeno, oxígeno y azufre. Este tamaño reducido es una característica clave que las diferencia de las macromoléculas y de los fármacos biológicos, y condiciona de forma directa su comportamiento farmacológico [8,7].

Una de las principales ventajas de las pequeñas moléculas reside en su elevada biodisponibilidad y permeabilidad:

- **Biodisponibilidad oral:** Debido a su bajo peso molecular y propiedades fisicoquímicas, estas moléculas presentan una alta probabilidad de absorción eficiente en el tracto gastrointestinal, lo que permite su administración por vía oral.
- **Permeabilidad celular y tisular:** Su tamaño compacto les otorga una capacidad superior para penetrar membranas biológicas y alcanzar dianas terapéuticas intracelulares que no son accesibles para anticuerpos o proteínas.
- **Penetración en tejidos:** Presentan una mejor distribución en tejidos sólidos, como los tumores poco vascularizados, lo que las hace especialmente valiosas en terapias oncológicas e inmunomoduladoras.
- **Estabilidad y coste:** Además de su eficacia biológica, ofrecen ventajas prácticas como una mayor estabilidad en condiciones fisiológicas y menores costes de producción en comparación con los fármacos biológicos.

Small Molecule vs Large Molecule




Figura 2.1: Comparación entre pequeñas moléculas y macromoléculas biológicas.

Para garantizar que estas moléculas sean candidatos viables, se suelen aplicar criterios de *drug-likeness*, como la Regla de Cinco de Lipinski, que utiliza propiedades como el peso molecular (típicamente < 500 Da), la lipofilicidad y la capacidad de formar enlaces de hidrógeno para predecir la biodisponibilidad oral y el éxito clínico de un compuesto.

2.2.2. Propiedades drug-like y calidad molecular

La evaluación de la *drug-likeness* o semejanza a fármaco constituye un filtro crítico para identificar compuestos con alta probabilidad de éxito clínico en función de sus propiedades físico-químicas. Históricamente, este concepto ha estado guiado por la Regla de Cinco de Lipinski, formulada en 1997 para predecir la absorción oral y la permeabilidad de un compuesto a partir del análisis de fármacos activos por vía oral. Sus criterios fundamentales incluyen un peso molecular inferior a 500 Da, un LogP menor de 5 y límites en el número de donadores y aceptores de enlaces de hidrógeno.

No obstante, para superar la naturaleza binaria y rígida de estas reglas, se desarrolló el concepto de *drug-likeness* continuo mediante el QED (*Quantitative Estimate of Drug-likeness*). El QED proporciona una puntuación entre 0 (no *drug-like*) y 1 (altamente *drug-like*), integrando ocho descriptores moleculares, como el área de superficie polar (TPSA) y la aromaticidad, y comparándolos con la distribución de fármacos ya aprobados en el mercado. Esta métrica permite una evaluación más matizada y prioriza candidatos con perfiles farmacéuticos prometedores más allá de filtros estrictos [9].

Valores altos de QED indican perfiles farmacéuticos favorables. De forma complementaria, el *synthetic accessibility score* (SAS) estima la viabilidad de sintetizar un compuesto en el laboratorio. Este índice integra la frecuencia de aparición de fragmentos estructurales y penalizaciones asociadas a la complejidad molecular, lo que lo convierte en un indicador práctico y amplia-

mente utilizado de la tratabilidad química. Las moléculas con valores favorables de QED y SAS presentan una mayor probabilidad de avanzar con éxito desde la generación computacional hasta la validación experimental [9].

Un valor bajo de SAS indica una síntesis sencilla, mientras que valores cercanos a 10 corresponden a estructuras extremadamente complejas. En el contexto de los modelos generativos, el SAS resulta especialmente relevante, ya que estos algoritmos, si no se restringen adecuadamente, pueden proponer estructuras físicamente improbables, “antinaturales” o inviables desde el punto de vista sintético. La incorporación del SAS en esquemas de optimización multiobjetivo garantiza que los candidatos generados no solo sean teóricamente potentes, sino también químicamente accesibles para su validación experimental y eventual escalado industrial [13].

En conjunto, los candidatos óptimos se sitúan en la región de alto QED y bajo SAS, lo que pone de manifiesto la necesidad de equilibrar las propiedades farmacocinéticas con la viabilidad sintética.

Perfil ADMET

Para que una molécula pequeña sea eficaz, no basta con que presente una alta afinidad por su diana; también debe poseer un perfil adecuado de ADMET, acrónimo de Absorción, Distribución, Metabolismo, Excreción y Toxicidad. Estas propiedades determinan la farmacocinética y la seguridad del compuesto, definiendo cómo se absorbe en el organismo, cómo se distribuye en los tejidos, cómo se metaboliza y cómo se elimina sin provocar efectos adversos [7].

La optimización temprana del perfil ADMET es fundamental, ya que el fracaso en estos parámetros constituye la principal causa de que aproximadamente el 90 % de los candidatos a fármacos no superen los ensayos clínicos. En los últimos años, se han desarrollado modelos predictivos basados en aprendizaje automático capaces de estimar estas propiedades a partir de la estructura molecular. Herramientas como ADMET-AI permiten evaluar de forma rápida grandes bibliotecas químicas, facilitando la integración de estas restricciones en las primeras etapas del diseño molecular.

2.2.3. EGFR como diana terapéutica

El receptor del factor de crecimiento epidérmico (EGFR) es una proteína transmembrana clave en la regulación de la señalización celular, el crecimiento y la supervivencia de las células. Su papel en el cáncer es crítico, ya que su sobreexpresión o activación desregulada está implicada en la patogénesis de diversos tumores sólidos, siendo especialmente relevante en el cáncer de pulmón de células no pequeñas (NSCLC) y en glioblastomas.

A pesar del éxito de los inhibidores de tirosina quinasa (TKI), la aparición de mutaciones de resistencia limita de forma significativa su eficacia clínica. Mutaciones como T790M (conocida como la mutación “gatekeeper”) dificultan la unión de los fármacos de primera y segunda generación, mientras que la mutación C797S suele emerger tras el tratamiento con inhibidores de tercera generación. Esta resistencia farmacológica sostenida genera una necesidad urgente de diseñar nuevas entidades químicas capaces de unirse eficazmente a estos sitios mutados, manteniendo un equilibrio adecuado entre selectividad y afinidad para superar los mecanismos de evasión tumoral[10].




Figura 2.2: Esquema de la vía de señalización del EGFR y sus principales mutaciones en el cáncer de pulmón de células no pequeñas (NSCLC).

2.3. Representación Computacional de Moléculas y Proteínas

La representación computacional de moléculas y proteínas constituye un elemento fundamental en el diseño de fármacos asistido por inteligencia artificial, ya que determina cómo los modelos procesan la información química y biológica. La elección de la representación condiciona tanto el espacio de búsqueda explorado por los modelos generativos como la capacidad de capturar interacciones relevantes para la afinidad fármaco-diana.

2.3.1. Representación lineal mediante SMILES

El sistema SMILES (Simplified Molecular Input Line Entry System) representa moléculas como secuencias de caracteres que codifican átomos, enlaces y estructuras cíclicas. Formalmente, una molécula puede representarse como una secuencia:

$$S = (s_1, s_2, \dots, s_n), \quad s_i \in \mathcal{V} \quad (2.1)$$

donde $\mathcal{V}$ es el vocabulario de símbolos químicos (átomos, enlaces, paréntesis, índices de ciclo, etc.).

Por ejemplo, la molécula de etanol puede representarse como:

$$\text{CCO} \quad (2.2)$$

Esta notación permite tratar las moléculas como texto, facilitando la aplicación de modelos de lenguaje inspirados en el procesamiento del lenguaje natural (NLP), como los basados en arquitecturas Transformer.

Una de sus principales ventajas es su simplicidad y escalabilidad, lo que permite entrenar modelos generativos sobre grandes bases de datos químicas. Sin embargo, esta representación no captura explícitamente la estructura tridimensional de las moléculas, lo que puede limitar la modelización de interacciones espaciales.

2.3.2. Representación basada en grafos moleculares

Una alternativa más estructural consiste en representar las moléculas como grafos. Formalmente, una molécula puede definirse como un grafo:

$$G = (V, E) \quad (2.3)$$

donde V es el conjunto de nodos (átomos) y E el conjunto de aristas (enlaces químicos). Cada nodo $v_i \in V$ puede asociarse a un vector de características x_i (tipo de átomo, carga, hibridación), y cada arista $e_{ij} \in E$ a propiedades del enlace.

2.3.3. Representación de proteínas y sitios de unión

En el contexto del diseño de fármacos, la representación de la proteína diana es clave para modelar la interacción con los ligandos, especialmente en casos como *EGFR* (Epidermal Growth Factor Receptor).

Los modelos de lenguaje de proteínas (Protein Language Models, PLMs) permiten obtener embeddings a partir de secuencias de aminoácidos. De forma análoga a SMILES, una proteína puede representarse como:

$$P = (a_1, a_2, \dots, a_m), \quad a_i \in \mathcal{A} \quad (2.4)$$

donde $\mathcal{A}$ es el alfabeto de aminoácidos.

Por otro lado, las representaciones basadas en el *binding pocket* se centran en la región estructural donde ocurre la interacción ligando-proteína. En este caso, el entorno del bolsillo puede modelarse como un subconjunto espacial:

$$\mathcal{P} \subset \mathbb{R}^3 \quad (2.5)$$

donde cada punto contiene información geométrica y fisicoquímica relevante para la afinidad de unión.

Estas aproximaciones permiten capturar interacciones moleculares de manera más precisa, aunque requieren información estructural tridimensional detallada.

2.4. Modelado predictivo de propiedades moleculares

La generación de nuevas moléculas constituye solo una parte del problema en el descubrimiento computacional de fármacos. Para que un compuesto generado pueda considerarse un candidato prometedor, es necesario estimar de manera eficiente distintas propiedades relacionadas con su actividad biológica, su perfil farmacocinético y su viabilidad química. Estos modelos son fundamentales para priorizar candidatos y optimizar la asignación de recursos en las etapas tempranas del descubrimiento de fármacos.

2.4.1. Modelos QSAR en descubrimiento de fármacos

Los modelos QSAR (*Quantitative Structure–Activity Relationship*) constituyen una de las herramientas más consolidadas de la química computacional aplicada al descubrimiento de fármacos. Su principio fundamental consiste en establecer una relación cuantitativa entre la estructura de una molécula y una propiedad biológica de interés, como la actividad frente a una diana, la potencia inhibitoria o la afinidad de unión. Para ello, las moléculas se representan mediante descriptores fisicoquímicos, huellas moleculares (*fingerprints*) o representaciones aprendidas automáticamente, que sirven como variables de entrada para algoritmos supervisados.

En el contexto del descubrimiento de fármacos, los QSAR desempeñan un papel especialmente relevante en fases tempranas de cribado virtual. Frente a métodos estructurales más costosos, como el *docking*, estos modelos ofrecen una alternativa computacionalmente eficiente para evaluar grandes cantidades de compuestos en poco tiempo. Su utilidad práctica reside en que permiten priorizar moléculas con mayor probabilidad de presentar actividad biológica, reduciendo así el espacio de búsqueda antes de aplicar técnicas de validación más exigentes.

Además de su eficiencia, una ventaja importante de los modelos QSAR es su flexibilidad. Pueden entrenarse para tareas de clasificación, por ejemplo distinguiendo compuestos activos e inactivos, o para tareas de regresión, como la predicción de valores continuos de afinidad, IC_{50} , K_i o pIC_{50} . Esta versatilidad los convierte en herramientas especialmente adecuadas para integrarse dentro de pipelines computacionales en las que la actividad biológica debe evaluarse de forma masiva y repetible.

QSAR como aproximación a la afinidad frente a una diana

En problemas de diseño molecular asistido por inteligencia artificial, la afinidad frente a una diana terapéutica rara vez puede medirse de forma directa durante la etapa generativa. La validación experimental requiere ensayos bioquímicos o celulares, mientras que las aproximaciones estructurales de mayor fidelidad, como el *docking* o la simulación molecular, pueden resultar demasiado costosas para evaluar bibliotecas virtuales de gran tamaño. Por esta razón, es habitual recurrir a modelos QSAR entrenados específicamente sobre datos experimentales asociados a una diana concreta, utilizándolos como una aproximación o *proxy* de la actividad biológica.

Desde esta perspectiva, un modelo QSAR no sustituye a la medición experimental de afinidad, pero sí proporciona una estimación cuantitativa que permite comparar y priorizar moléculas candidatas. En particular, cuando el modelo se entrena con datos consistentes de actividad frente a una proteína determinada, puede captar regularidades estructurales asociadas a la unión ligando-diana y ofrecer una señal útil para guiar la selección de compuestos.

Los modelos QSAR presentan limitaciones importantes que deben considerarse al interpretar sus predicciones. Su rendimiento depende en gran medida de la calidad, cantidad y diversidad de los datos de entrenamiento, por lo que conjuntos de datos sesgados o con ruido pueden comprometer su fiabilidad. Además, solo son aplicables dentro de su dominio de aplicabilidad, es decir, para moléculas similares a las utilizadas en su desarrollo, perdiendo validez al extrapolar a nuevas estructuras. Asimismo, capturan correlaciones entre estructura y actividad sin modelar explícitamente los mecanismos fisicoquímicos subyacentes, lo que limita su capacidad de generalización. Por último, al basarse habitualmente en una única variable experimental, simplifican

la complejidad del fenómeno biológico, ignorando factores como la permeabilidad, la estabilidad metabólica o las condiciones del ensayo, por lo que deben emplearse como herramientas complementarias dentro de un análisis más amplio.




Figura 2.3: Esquema general de un modelo QSAR: a partir de datos de actividad experimental se generan predicciones y alertas estructurales.

2.4.2. Predicción computacional de propiedades ADMET

Además de mostrar afinidad frente a una diana terapéutica, un candidato a fármaco debe presentar un perfil adecuado de absorción, distribución, metabolismo, excreción y toxicidad. Estas propiedades, agrupadas bajo el acrónimo ADMET, condicionan de manera decisiva el comportamiento del compuesto en un organismo y representan una de las principales causas de fracaso en fases avanzadas del desarrollo farmacéutico. Como consecuencia, la evaluación temprana de estas dimensiones se ha convertido en un componente esencial dentro de los flujos de diseño molecular asistido por inteligencia artificial.

La predicción computacional de propiedades ADMET busca estimar, a partir de la estructura química, aspectos como la permeabilidad intestinal, la capacidad de atravesar membranas biológicas, la interacción con transportadores, la estabilidad metabólica, el riesgo de hepatotoxicidad o la posible cardiotoxicidad, entre otros. Estas predicciones permiten descartar de forma temprana compuestos con perfiles desfavorables antes de invertir recursos en síntesis o validación experimental, mejorando así la eficiencia global del proceso de priorización.

A diferencia de la actividad frente a una diana concreta, que suele formularse como una tarea específica de clasificación o regresión, la evaluación ADMET es intrínsecamente multidimensional. Una molécula puede mostrar un comportamiento favorable en ciertas propiedades y desfavorable en otras, lo que obliga a considerar compromisos entre múltiples criterios. Esta naturaleza compleja encaja especialmente bien con enfoques de optimización multiobjetivo, donde el objetivo no es maximizar una única magnitud, sino equilibrar distintos factores relevantes para la viabilidad farmacéutica.

Herramientas modernas de predicción ADMET basadas en IA

El crecimiento de los datos bioquímicos y farmacológicos disponibles ha impulsado el desarrollo de herramientas de predicción ADMET basadas en inteligencia artificial, capaces de estimar múltiples propiedades de forma automatizada y a gran escala.

Entre las principales ventajas de estos sistemas destaca su capacidad para evaluar múltiples *endpoints* simultáneamente. En lugar de analizar cada propiedad de forma aislada mediante procedimientos independientes, muchas herramientas modernas proporcionan una batería integrada de predicciones relacionadas con absorción oral, permeabilidad, distribución tisular, metabolismo mediado por enzimas, eliminación y toxicidad. Esta evaluación conjunta resulta especialmente útil en pipelines generativas, donde es necesario cribar rápidamente grandes conjuntos moleculares y detectar perfiles desfavorables con criterios homogéneos y reproducibles.

2.5. Modelos generativos moleculares

A diferencia de los enfoques tradicionales centrados en la evaluación de compuestos existentes, los modelos generativos permiten proponer nuevas estructuras químicas explorando regiones del espacio químico no cubiertas por bases de datos experimentales. Estos modelos aprenden distribuciones implícitas sobre representaciones moleculares a partir de grandes colecciones de compuestos, lo que les permite generar nuevas moléculas con características similares a las observadas durante el entrenamiento.

2.5.1. Generación molecular *de novo*

La generación molecular *de novo* consiste en diseñar nuevas entidades químicas sin partir directamente de compuestos existentes, sino a partir de patrones aprendidos sobre grandes conjuntos de datos moleculares. Este enfoque permite explorar de forma eficiente el espacio químico, que se estima extremadamente amplio, superando las limitaciones de los métodos tradicionales basados en bibliotecas físicas.

Formalmente, dado un conjunto de moléculas de entrenamiento $\mathcal{D} = \{x_1, x_2, \dots, x_n\}$, un modelo generativo aprende una distribución $p(x)$ sobre el espacio molecular tal que nuevas muestras $\tilde{x} \sim p(x)$ correspondan a estructuras químicamente válidas y plausibles. Dependiendo de la representación utilizada, estas muestras pueden generarse como secuencias (por ejemplo, SMILES) o como grafos moleculares.

Este paradigma ha permitido pasar de un enfoque de cribado pasivo a uno activo, en el que el modelo no solo evalúa moléculas, sino que también propone candidatos potenciales optimizados según ciertos criterios. En este sentido, el diseño molecular *de novo* puede entenderse como un proceso generativo guiado por conocimiento químico implícito aprendido a partir de datos.

Una de las principales motivaciones de este enfoque es la capacidad de explorar el espacio químico más allá de las bibliotecas tradicionales. Mientras que los conjuntos utilizados en cribado experimental suelen contener entre 10^4 y 10^8 moléculas, el espacio químico potencial se estima en más de 10^{60} compuestos factibles, lo que hace inviable su exploración exhaustiva mediante métodos clásicos.

2.5.2. Modelos generativos modernos

El desarrollo reciente de modelos de aprendizaje profundo ha impulsado la aparición de nuevas arquitecturas generativas más potentes y flexibles. Entre ellas, los modelos basados en **Transformers** han demostrado un rendimiento destacado en la generación de moléculas representadas como secuencias SMILES. Inspirados en el procesamiento del lenguaje natural, estos modelos utilizan mecanismos de atención para capturar dependencias globales en la secuencia, permitiendo modelar relaciones entre átomos y enlaces independientemente de su posición en la cadena y mejorando la coherencia sintáctica de las moléculas generadas.

Paralelamente, los modelos generativos basados en **grafos** han ganado relevancia al generar directamente estructuras moleculares en forma de grafos. Más recientemente, los **modelos de difusión** han emergido como una de las aproximaciones más prometedoras. Estos modelos generan moléculas mediante un proceso iterativo de eliminación de ruido, transformando progresivamente una distribución inicial aleatoria en estructuras químicas válidas. Además, han demostrado ser especialmente eficaces en la generación de conformaciones tridimensionales y en el modelado de propiedades invariantes a rotaciones y traslaciones, lo que resulta relevante para la representación espacial de moléculas.

Asimismo, las **redes neuronales de grafos** (GNN) han sido ampliamente utilizadas tanto en generación como en predicción molecular, ya que permiten operar directamente sobre la estructura del grafo molecular y modelar interacciones locales entre átomos mediante mecanismos de *message passing*.

2.5.3. Modelos preentrenados en química molecular

Una tendencia reciente en el desarrollo de modelos generativos moleculares es el uso de modelos preentrenados. En este enfoque, los modelos se entrenan inicialmente sobre grandes bases de datos químicas, como ZINC, ChEMBL o PubChem, con el objetivo de aprender representaciones generales del espacio molecular sin necesidad de etiquetas explícitas.

El uso de aprendizaje auto-supervisado permite a estos modelos capturar la “gramática” subyacente de la química, es decir, las regularidades estructurales y sintácticas que definen las moléculas válidas. Posteriormente, estos modelos pueden reutilizarse directamente o adaptarse a tareas específicas mediante técnicas de *fine-tuning*, reduciendo la necesidad de datos etiquetados para nuevas dianas.

Ejemplos de este enfoque incluyen modelos tipo GPT como **TamGen**, entrenado sobre millones de cadenas SMILES, o modelos de fundación como **ChemBERTa** y **MegaMolBART**, que pueden adaptarse a múltiples tareas dentro del descubrimiento de fármacos, desde la predicción de propiedades hasta la generación y optimización molecular.

El preentrenamiento permite mejorar la capacidad de generalización del modelo, reducir el coste computacional asociado al entrenamiento desde cero y facilitar la transferencia de conocimiento entre distintos problemas. .

2.6. Optimización multiobjetivo en diseño molecular

El diseño de moléculas con potencial terapéutico constituye un problema intrínsecamente multiobjetivo, en el que deben considerarse simultáneamente múltiples propiedades relevantes y, en muchos casos, conflictivas. A diferencia de otros problemas de optimización donde existe una única función objetivo claramente definida, en el descubrimiento de fármacos es necesario equilibrar criterios como la afinidad frente a una diana, las propiedades farmacocinéticas, la toxicidad y la viabilidad sintética.

2.6.1. Naturaleza multiobjetivo del descubrimiento de fármacos

El proceso de descubrimiento de fármacos implica la optimización simultánea de múltiples propiedades que no siempre están alineadas entre sí. Por ejemplo, aumentar la afinidad frente a una diana terapéutica puede implicar un incremento de la lipofilidad, lo que a su vez puede afectar negativamente a la solubilidad o incrementar el riesgo de toxicidad. De manera similar, moléculas altamente complejas pueden mostrar una elevada actividad biológica, pero resultar difíciles o costosas de sintetizar.

Este tipo de relaciones introduce tensiones inherentes entre objetivos, lo que impide definir una solución óptima única en sentido clásico. En su lugar, el problema debe abordarse como un conjunto de objetivos:

$$\text{máx } f_1(x), \quad \text{máx } f_2(x), \quad \dots, \quad \text{mín } f_k(x) \quad (2.6)$$

donde cada función $f_i(x)$ representa una propiedad relevante del compuesto x , como la afinidad estimada, el índice de *drug-likeness* (QED) o la accesibilidad sintética (SAS).

En este marco, el objetivo no es encontrar una única solución óptima, sino un conjunto de soluciones que representen los mejores compromisos posibles entre los distintos criterios.

2.6.2. Estrategias de optimización molecular

Diversas estrategias han sido propuestas para abordar la optimización de propiedades moleculares en el contexto de la generación *de novo*. Una de las aproximaciones más comunes consiste en combinar múltiples objetivos en una única función escalar mediante **ponderaciones**:

$$F(x) = \sum_{i=1}^k w_i f_i(x) \quad (2.7)$$

donde w_i representa el peso asignado a cada objetivo. Aunque este enfoque es sencillo de implementar, presenta limitaciones importantes, ya que requiere definir a priori la importancia relativa de cada criterio y puede ocultar la estructura real de compromisos entre objetivos.

Otra estrategia ampliamente utilizada es el aprendizaje por refuerzo, en el que el modelo generativo se optimiza mediante una **función de recompensa** que combina distintas propiedades. Este enfoque ha demostrado ser eficaz en ciertos escenarios, pero también tiende a reducir el problema multiobjetivo a una señal escalar, lo que puede dificultar la exploración de soluciones diversas.

Asimismo, los algoritmos evolutivos han sido aplicados al diseño molecular, utilizando operadores de mutación y selección para evolucionar poblaciones de moléculas a lo largo de múltiples generaciones. Estos métodos permiten mantener diversidad en las soluciones, pero pueden resultar costosos computacionalmente y difíciles de integrar con modelos generativos complejos.

2.6.3. Dominancia de Pareto y soluciones no dominadas

La optimización multiobjetivo puede abordarse de forma natural mediante el concepto de dominancia de Pareto. A diferencia de los problemas con un único objetivo, en este contexto no existe una única solución óptima, sino un conjunto de soluciones que representan distintos equilibrios entre los objetivos considerados.

Formalmente, una solución x_1 domina a otra solución x_2 si es al menos tan buena en todos los objetivos y estrictamente mejor en al menos uno de ellos:

$$x_1 \prec x_2 \iff \forall i, f_i(x_1) \geq f_i(x_2) \text{ y } \exists j \text{ tal que } f_j(x_1) > f_j(x_2) \quad (2.8)$$

El conjunto de soluciones que no son dominadas por ninguna otra se denomina conjunto de Pareto, y su proyección en el espacio de objetivos define el frente de Pareto. Las soluciones que pertenecen a este frente se denominan soluciones no dominadas. En ellas, no es posible mejorar un objetivo sin empeorar al menos uno de los otros.




Figura 2.4: Ejemplo de frente de Pareto en un problema multiobjetivo.

El concepto de óptimo de Pareto puede entenderse de forma intuitiva mediante su representación gráfica. En la Figura 2.4, la solución a pertenece al conjunto de soluciones no dominadas, ya que no existe otra solución que mejore simultáneamente todos sus objetivos. En otras palabras, cualquier mejora en uno de los objetivos implicaría necesariamente un empeoramiento en al menos otro.

Por el contrario, la solución c es una solución dominada, ya que existen otras soluciones, como a o b , que presentan un mejor comportamiento en los objetivos considerados. En este sentido, las soluciones dominadas pueden descartarse en el proceso de selección, mientras que

las soluciones no dominadas constituyen el conjunto de candidatos óptimos bajo el criterio de Pareto.

2.6.4. Métricas de evaluación multiobjetivo

Una vez definido el concepto de frente de Pareto, es necesario contar con herramientas que permitan evaluar la calidad de un conjunto de soluciones. En el contexto del diseño molecular, esto implica medir no solo si las moléculas son buenas individualmente, sino también si el conjunto cubre adecuadamente distintos compromisos entre propiedades.

Hipervolumen (*Hypervolume*)

Una de las métricas más utilizadas es el hipervolumen (*hypervolume*, HV). Esta mide el volumen del espacio de objetivos que es dominado por el conjunto de soluciones respecto a un punto de referencia z (generalmente elegido como un punto peor que todas las soluciones).

De forma simplificada, el hipervolumen puede entenderse como el área (en 2D) o volumen (en dimensiones superiores) cubierto por las soluciones no dominadas.

Por ejemplo, si tenemos dos objetivos (maximizar afinidad y maximizar QED), cada molécula define un punto en un plano. El hipervolumen mide cuánto espacio *bueno* cubren esas moléculas. Cuanto mayor sea este valor, mejor será el conjunto, ya que implica que se han encontrado soluciones que cubren una región más amplia y favorable.

Dispersión (*Spread*)

Otra métrica importante es la dispersión o *spread*, que mide cómo se distribuyen las soluciones a lo largo del frente de Pareto.

Imaginemos que todas las moléculas generadas tienen valores muy similares de afinidad y QED. Aunque sean buenas, el conjunto no es diverso. En cambio, si algunas priorizan afinidad y otras priorizan QED, se obtiene una mejor cobertura del espacio.

Número de soluciones no dominadas

Una medida sencilla pero útil es el número de soluciones no dominadas, es decir, el tamaño del frente de Pareto. Si tras generar 1000 moléculas solo 3 son no dominadas, el modelo está produciendo pocas soluciones competitivas. Si hay 50, entonces el modelo está explorando mejor el espacio.

Funciones agregadas (DScore)

En algunos enfoques se combinan varios objetivos en una única función escalar:

$$D(x) = \sum_{i=1}^k w_i f_i(x) \quad (2.9)$$

donde w_i son pesos asignados a cada objetivo. Sin embargo, este enfoque tiene una limitación importante: requiere decidir cuánto pesa cada objetivo, lo que introduce arbitrariedad.

Capítulo 3

Materiales y métodos

El presente capítulo describe la metodología seguida para desarrollar la *pipeline* computacional propuesta. El trabajo se estructuró como una investigación aplicada e incremental: primero se preparó un conjunto de datos fiable de actividad frente a EGFR, después se adaptó un modelo generativo molecular preentrenado, posteriormente se evaluaron las moléculas generadas mediante criterios de actividad, propiedades fisicoquímicas, ADMET y similitud estructural, y finalmente se aplicó una selección multiobjetivo basada en dominancia de Pareto.

La decisión metodológica central fue no entrenar todos los componentes desde cero, sino integrar herramientas y modelos especializados dentro de un flujo reproducible. Esta elección es coherente con el objetivo del trabajo: diseñar y evaluar una arquitectura de inteligencia artificial aplicada al descubrimiento molecular, más que proponer un nuevo algoritmo generativo o un nuevo modelo QSAR. Por ello, cada fase de la *pipeline* se diseñó como un bloque independiente, con entradas y salidas persistidas en disco, permitiendo auditar los resultados intermedios y repetir el proceso completo de forma controlada.

3.1. Diseño general de la metodología

La metodología se dividió en cuatro etapas principales, implementadas en notebooks independientes:

- **Preprocesado del dataset de bioactividad:** limpieza, normalización, canonicalización y agregación de datos experimentales de IC50 frente a EGFR.
- **Fine-tuning y generación molecular:** adaptación de un modelo generativo preentrenado de SMILES al espacio químico de moléculas activas frente a EGFR.
- **Scoring y selección multiobjetivo:** cálculo de descriptores, entrenamiento de un modelo QSAR, predicción de pIC50, integración de ADMET-AI, cálculo de similitudes estructurales y selección mediante Pareto.
- **Análisis posterior de candidatas:** interpretación de la shortlist final desde diferentes perfiles: actividad, ADMET, novedad, diversidad estructural y equilibrio global.

Esta separación evita mezclar objetivos metodológicos distintos. El modelo generativo aprende de una distribución de secuencias SMILES; los descriptores fisicoquímicos, las predicciones de actividad y las restricciones ADMET pertenecen a la fase posterior de evaluación. Incluir estas variables directamente en el entrenamiento del LSTM no aportaría información útil, ya que el modelo empleado no es condicional. Por tanto, la optimización se realiza *post-generación*, mediante scoring y selección multiobjetivo.

Notebook	Función principal	Salida principal
01_preprocesado	Limpieza y agregación del dataset de IC50 frente a EGFR.	model_preprocesed_dataset.csv y model_procesed_dataset.csv.
02_SMILES_generation	Fine-tuning del modelo MRL y generación de moléculas nuevas.	generated_molecules.csv.
03_scoring	Scoring, ADMET, similitud, Pareto y shortlist final.	shortlist30_final_candidates.csv.
04_conclusiones	Análisis interpretativo de candidatas y generación de figuras de apoyo.	Tablas, rankings y visualizaciones para discusión de resultados.

Cuadro 3.1: Estructura modular de los notebooks empleados en el desarrollo de la pipeline.

3.2. Materiales, entorno y librerías empleadas

El desarrollo se realizó en Python, utilizando notebooks de Jupyter como entorno principal de experimentación. La elección de notebooks se justifica por su utilidad en proyectos exploratorios de ciencia de datos, ya que permiten combinar código, resultados intermedios, visualizaciones y justificación metodológica en un mismo documento ejecutable.

Las principales librerías empleadas fueron:

- **RDKit**: validación y canonicalización de SMILES, cálculo de descriptores fisicoquímicos, fingerprints Morgan, coeficientes de Tanimoto y scaffolds de Murcko.
- **MRL**: carga del modelo molecular generativo preentrenado y fine-tuning supervisado sobre SMILES activos frente a EGFR.
- **PyTorch**: backend de entrenamiento del modelo generativo.
- **scikit-learn**: entrenamiento del modelo QSAR basado en Random Forest y cálculo de métricas de regresión.
- **ADMET-AI**: predicción de propiedades farmacocinéticas y toxicológicas de las moléculas generadas [3].
- **pandas, numpy y matplotlib**: manipulación de datos, análisis numérico y visualización.

Para garantizar reproducibilidad, se fijó una semilla común de aleatoriedad igual a **42** en las fases de generación, particionado de datos y entrenamiento del modelo predictivo. Además, cada fase generó archivos intermedios en carpetas diferenciadas, separando datos, modelos, resultados finales y resúmenes de ejecución.

3.3. Preprocesado del dataset de bioactividad EGFR

3.3.1. Datos de entrada y exportación desde ChEMBL

La primera etapa del trabajo consistió en construir un dataset de bioactividad específico para EGFR a partir de datos experimentales procedentes de ChEMBL. La descarga se realizó directamente desde el explorador de actividades de ChEMBL, disponible en:

<https://www.ebi.ac.uk/chembl/explore/activities/>

Antes de exportar el archivo CSV, se aplicaron filtros en la propia interfaz web con el objetivo de restringir el conjunto inicial a registros relevantes para el caso de estudio.

En primer lugar, se utilizó el filtro personalizado `target_chembl_id:CHEMBL203`, correspondiente a la diana EGFR humana. Posteriormente, mediante los filtros interactivos de ChEMBL, se restringieron las actividades a:

- **Standard Type** = IC50, para conservar únicamente medidas de concentración inhibitoria media;
- **Target Organism** = *Homo sapiens*, para evitar mezclar datos procedentes de organismos distintos.

La aplicación de estos filtros previos generó el archivo `egfr_activity_IC50.csv`, que fue empleado como entrada del notebook `01_preprocesado.ipynb`. El archivo bruto contenía inicialmente 25.758 registros y 48 columnas. Esta exportación no se utilizó directamente para entrenar modelos, ya que todavía incluía columnas no necesarias, registros con unidades no homogéneas, relaciones experimentales censuradas y valores potencialmente problemáticos desde el punto de vista de validez experimental.

3.3.2. Datos de entrada

La primera etapa partió de un dataset bruto de actividad frente a EGFR en formato CSV, almacenado como `egfr_activity_IC50.csv`. El archivo contenía inicialmente 25.758 registros y 48 columnas. Tras eliminar columnas no necesarias para el objetivo del trabajo, el dataset quedó reducido a 21 columnas de interés.

El preprocesado se centró exclusivamente en medidas comparables de IC50 frente a EGFR. Para ello se aplicaron los siguientes criterios:

- diana igual a CHEMBL203, correspondiente a EGFR;
- tipo de medida igual a IC50;

- unidades normalizadas a nanomolar, nM;
- valores de actividad positivos;
- relación experimental exacta, `Standard Relation = '='`;
- exclusión de registros con comentarios de validez experimental problemáticos.

3.3.3. Canonicalización y agregación molecular

Los SMILES se canonicalizaron con RDKit antes de agregar registros. Esta decisión es importante porque una misma molécula puede aparecer escrita mediante diferentes cadenas SMILES. Si la agregación se hiciera antes de canonicalizar, podrían conservarse duplicados químicos ocultos y calcularse estadísticas separadas para la misma estructura.

Una vez canonicalizadas las moléculas, los registros experimentales se agregaron por SMILES canónico. Para la actividad se utilizó la mediana del valor IC50 en nM. La mediana es más robusta que la media frente a valores extremos o discrepancias entre ensayos, algo frecuente en bases de datos de bioactividad procedentes de distintas fuentes experimentales.

La actividad se transformó a pIC50 mediante la ecuación:

$$pIC50 = 9 - \log_{10}(IC50_{nM}) \quad (3.1)$$

Esta transformación permite trabajar en una escala logarítmica donde valores más altos indican mayor potencia. Además, se definieron dos etiquetas interpretativas:

- **activo**: molécula con $pIC50 \geq 6$;
- **fuertemente activo**: molécula con $pIC50 \geq 7$.

El dataset canónico final para análisis y modelado QSAR quedó compuesto por 10.466 moléculas y 11 variables. A partir de este conjunto se generó un segundo dataset mínimo, compuesto únicamente por SMILES activos, destinado al fine-tuning del modelo MRL. Este segundo archivo contiene 8.553 SMILES únicos.

3.3.4. Productos del preprocesado

El preprocesado generó dos productos con propósitos diferentes:

- `model_preprocesed_dataset.csv`: dataset completo y trazable, con SMILES canónicos, IC50 agregado, pIC50, etiquetas de actividad y variables procedentes de ChEMBL.
- `model_procesed_dataset.csv`: dataset mínimo para fine-tuning generativo, compuesto solo por la columna `smiles`.

Separar estos dos archivos fue una decisión deliberada. El modelo generativo solo necesita aprender una distribución de secuencias SMILES asociadas a moléculas activas.

3.4. Fine-tuning del modelo generativo molecular

3.4.1. Modelo generativo seleccionado

Para la generación molecular se empleó el modelo preentrenado `LSTM_LM_Small_ZINC_NC` de la librería MRL. Se trata de un modelo de lenguaje molecular basado en LSTM, preentrenado sobre moléculas representadas como SMILES. La ventaja de este enfoque es que permite reutilizar una distribución química previamente aprendida, reduciendo el coste computacional y evitando entrenar un generador desde cero.

El objetivo del fine-tuning no fue maximizar agresivamente la adaptación al dataset de EGFR, sino desplazar moderadamente la distribución generativa hacia regiones químicas compatibles con inhibidores de EGFR, manteniendo al mismo tiempo validez y diversidad molecular. Por ello se utilizó una tasa de aprendizaje baja, $5 \cdot 10^{-5}$, y se monitorizó la calidad generativa después de cada epoch.

Parámetro	Valor utilizado
Modelo preentrenado	LSTM_LM_Small_ZINC_NC
Semilla	42
<i>Drop scale</i>	0,30
<i>Learning rate</i>	$5 \cdot 10^{-5}$
Tamaño de batch de fine-tuning	32
Número máximo de epochs	8
Muestra de control por epoch	4.000 SMILES
Muestra final generada	10.000 SMILES brutos
Longitud máxima en generación final	120 caracteres
Exclusión de coincidencias exactas con entrenamiento	Sí

Cuadro 3.2: Hiperparámetros utilizados durante el fine-tuning y la generación final.

3.4.2. Monitorización por epoch y selección del checkpoint

Después de cada epoch se generó una muestra de control de 4.000 SMILES y se calcularon cuatro métricas:

- **validez RDKit**: proporción de SMILES interpretables como moléculas válidas;
- **unicidad raw**: proporción de cadenas SMILES crudas únicas;
- **unicidad canónica válida**: proporción de moléculas válidas únicas tras canonicalización;
- **novedad exacta**: proporción de moléculas válidas únicas no presentes exactamente en el conjunto de entrenamiento.

No se eligió automáticamente la última epoch. Esta decisión es relevante: en modelos generativos, una mayor exposición al dataset puede reducir la pérdida de entrenamiento, pero también aumentar el riesgo de sobreajuste, pérdida de diversidad o reproducción de estructuras demasiado cercanas al conjunto original. Por tanto, la elección del checkpoint se realizó considerando el equilibrio entre especialización y calidad generativa.

Se seleccionó la epoch 3 como modelo final. La epoch 1 presentaba métricas ligeramente superiores de validez y novedad, pero una sola pasada por el dataset podía ser insuficiente para consolidar patrones químicos del dominio EGFR-like. En la epoch 3 se mantenía una validez superior al 90 %, unicidad canónica del 100 % y novedad frente al entrenamiento del 99,94 %, mientras que a partir de epochs posteriores comenzaba a observarse una degradación progresiva de validez y novedad.

3.4.3. Generación final y limpieza

Con el checkpoint seleccionado se generaron 10.000 SMILES brutos. Posteriormente se aplicaron los siguientes pasos:

- validación mediante RDKit;
- canonicalización de SMILES;
- eliminación de duplicados canónicos;
- identificación y eliminación de coincidencias exactas con el conjunto de entrenamiento;
- exportación de moléculas válidas, únicas y nuevas respecto al training set.

El proceso produjo 9.082 SMILES válidos, 9.079 moléculas válidas únicas y 9.068 moléculas finales válidas, únicas y no presentes exactamente en el conjunto de entrenamiento. Estas 9.068 moléculas constituyeron la entrada principal de la fase de scoring.

3.5. Cálculo de descriptores y filtro químico básico

Antes de aplicar modelos predictivos más costosos, cada molécula generada fue evaluada con descriptores fisicoquímicos calculados mediante RDKit. Se calcularon, entre otros, peso molecular, LogP, TPSA, donadores y aceptores de enlace de hidrógeno, enlaces rotables, número de anillos, átomos pesados, QED, violaciones de la regla de Lipinski y scaffold de Murcko.

El filtro químico básico se diseñó como una barrera inicial de plausibilidad farmacológica. No pretende demostrar que una molécula pueda ser un fármaco, sino descartar estructuras claramente poco razonables antes de dedicar recursos a predicción de actividad, ADMET y selección multiobjetivo.

Criterio	Rango o umbral
Peso molecular	180–650 Da
RDKit LogP	-1–6,5
TPSA	20–160
Donadores de H	≤ 5
Aceptores de H	≤ 12
Enlaces rotables	≤ 12
Átomos pesados	10–70
Violaciones Lipinski	≤ 2
QED	$\geq 0,25$

Cuadro 3.3: Filtros fisicoquímicos básicos aplicados a las moléculas generadas.

Los límites se fijaron de forma deliberadamente permisiva. Por ejemplo, se admitieron hasta dos violaciones de Lipinski porque algunos inhibidores de EGFR pueden ser relativamente grandes o lipofílicos. Del mismo modo, el umbral de QED se fijó en 0,25 para excluir moléculas de calidad farmacológica muy baja sin imponer una presión de selección excesiva en una fase temprana.

Tras este filtrado, 8.241 de las 9.068 moléculas generadas fueron conservadas, lo que representa un 90,88 % del conjunto. Este resultado indica que el modelo generativo no produjo únicamente cadenas SMILES válidas, sino también moléculas con propiedades fisicoquímicas razonables para continuar el análisis.

3.6. Modelo QSAR para estimación de actividad frente a EGFR

Para aproximar la actividad frente a EGFR se entrenó un modelo QSAR de regresión sobre el dataset canónico de referencia. Cada molécula se representó mediante fingerprints Morgan con radio 2 y 2.048 bits.

3.6.1. Partición por scaffold

La evaluación del modelo se realizó mediante partición por scaffold de Murcko, con una proporción aproximada 80/10/10 para entrenamiento, validación y test. Esta decisión es más estricta que una partición aleatoria, ya que reduce el riesgo de evaluar el modelo sobre moléculas estructuralmente casi idénticas a las utilizadas durante el entrenamiento.

El conjunto de referencia quedó dividido en:

- 8.402 moléculas de entrenamiento;
- 1.065 moléculas de validación;
- 999 moléculas de test.

3.6.2. Modelo predictivo y métricas

Se entrenó un *Random Forest Regressor* con 500 árboles, `max_features = sqrt`, `min_samples_leaf = 2`, paralelización mediante `n_jobs = -1` y semilla 42.

La elección de Random Forest se justifica por tres razones. Primero, proporciona un baseline robusto para fingerprints moleculares sin requerir una red neuronal adicional. Segundo, puede capturar relaciones no lineales entre subestructuras y actividad. Tercero, es suficientemente interpretable desde el punto de vista metodológico para una pipeline cuyo objetivo principal es la integración y priorización multiobjetivo, no la optimización exhaustiva del modelo QSAR.

Conjunto	MAE	RMSE	R^2	Spearman
Validación	0,648	0,830	0,584	0,773
Test	0,649	0,833	0,605	0,798

Cuadro 3.4: Rendimiento del modelo QSAR de pIC50 basado en Random Forest y fingerprints Morgan.

El modelo se utilizó como herramienta de ranking relativo, no como estimador absoluto perfecto de actividad. Por ello, diferencias pequeñas de pIC50 no se sobreinterpretaron. La actividad predicha se combinó posteriormente con criterios ADMET, similitud, QED y diversidad estructural.

Sobre las 8.241 moléculas filtradas, la pIC50 predicha presentó una media de 6,14 y una mediana de 6,11. De ellas, 5.445 moléculas fueron clasificadas como activas predichas ($pIC50 \geq 6$) y 162 como fuertemente activas ($pIC50 \geq 7$). Este resultado justifica la necesidad de una selección posterior: el generador produce muchas moléculas razonablemente activas, pero solo una fracción reducida alcanza valores altos de actividad estimada.

3.7. Similitud estructural y control de novedad

La novedad molecular no se evaluó únicamente eliminando coincidencias exactas con el conjunto de entrenamiento. También se calculó la similitud máxima de Tanimoto frente a las moléculas usadas en el fine-tuning, utilizando fingerprints Morgan.

Esta métrica cumple una doble función:

- detectar moléculas demasiado próximas al conjunto de entrenamiento, que podrían ser análogos triviales;
- detectar moléculas demasiado alejadas, donde el modelo QSAR podría estar extrapolando fuera de su dominio de aplicabilidad.

La similitud media frente al conjunto de entrenamiento fue 0,30, con mediana de 0,28. Esto indica que la mayoría de moléculas generadas no son copias directas del training set. Sin embargo, se detectaron dos moléculas con similitud mayor o igual a 0,95, consideradas casi copias y excluidas en la fase de elegibilidad.

Para el scoring posterior se definió una ventana deseable de similitud entre 0,35 y 0,85. Valores por debajo de 0,30 se trataron como potencialmente fuera del dominio aproximado del

modelo; valores superiores a 0,95 se trataron como riesgo de copia estructural. Esta decisión equilibra dos objetivos que suelen entrar en conflicto: novedad química y aplicabilidad del modelo predictivo.

3.8. Integración de predicciones ADMET-AI

Las moléculas filtradas se evaluaron con ADMET-AI para estimar propiedades farmacocinéticas y toxicológicas relevantes [3]. Se preparó un archivo de entrada con 8.241 SMILES únicos y se ejecutaron las predicciones por lotes de 1.000 moléculas. Posteriormente, las predicciones se integraron con el dataframe principal mediante SMILES canónico.

Dado que ADMET-AI devuelve numerosas columnas, se separaron dos tipos de señal:

- **filtros ADMET duros**: reglas críticas que una molécula debe cumplir para reducir riesgos tempranos;
- **score ADMET blando**: agregación ponderada de percentiles frente a moléculas aprobadas de DrugBank.

Esta separación evita que una alerta grave de toxicidad quede escondida dentro de una media global aparentemente aceptable.

3.8.1. Filtros ADMET duros

Se definieron reglas estrictas para alertas estructurales, toxicidad y absorción. Las reglas se muestran en la Tabla 3.5.

Variable ADMET	Criterio de aceptación
PAINS_alert	= 0
NIH_alert	= 0
BRENK_alert	≤ 1
AMES	$\leq 0,5$
ClinTox	$\leq 0,5$
Carcinogens_Lagunin	$\leq 0,5$
hERG	$\leq 0,5$
Bioavailability_Ma	$\geq 0,5$
HIA_Hou	$\geq 0,5$

Cuadro 3.5: Reglas ADMET duras aplicadas durante el scoring.

Para cada molécula se calculó la fracción de reglas duras superadas. La media fue 0,88, con una mediana de 0,889. En la fase de elegibilidad se exigió una fracción mínima de 0,75, permitiendo cierta flexibilidad pero excluyendo perfiles con múltiples riesgos críticos.

3.8.2. Score ADMET blando

Además de los filtros duros, se construyó un score ADMET blando usando percentiles frente a moléculas aprobadas de DrugBank. Para endpoints de toxicidad o riesgo, como AMES, ClinTox, carcinogenicidad, hERG, DILI o reacciones cutáneas, se consideraron preferibles percentiles bajos. Para propiedades relacionadas con exposición, absorción y solubilidad, se consideraron preferibles percentiles altos.

Los componentes se transformaron a una escala 0–1 y se combinaron mediante una media ponderada. Se asignó mayor peso a riesgos críticos como hERG y ClinTox, y menor peso a interacciones CYP, que fueron tratadas como penalizaciones blandas. Esta ponderación refleja una decisión metodológica: en fases tempranas de priorización, las señales graves de seguridad deben influir más que alertas metabólicas exploratorias.

3.9. Construcción de scores interpretables

Para combinar variables heterogéneas se construyeron scores normalizados en escala 0–1. Esta transformación evita comparar directamente magnitudes con unidades diferentes, como pIC50, QED, similitud de Tanimoto y fracciones de filtros superados.

Se definieron los siguientes componentes:

- **score_activity**: transformación lineal de pIC50 entre 6,0 y 7,5;
- **score_admet**: score ADMET blando normalizado;
- **score_admet_hard**: fracción de filtros ADMET duros superados;
- **score_training_similarity**: puntuación máxima para similitud entre 0,35 y 0,85, penalizando moléculas demasiado lejanas o demasiado próximas;
- **score_qed**: QED directamente truncado entre 0 y 1;
- **score_ro5**: penalización según número de violaciones de Lipinski.

A partir de estos componentes se calculó un score global interpretable:

$$R(x) = \frac{\sum_{i=1}^k w_i s_i(x)}{\sum_{i=1}^k w_i} \quad (3.2)$$

Donde $s_i(x)$ representa cada componente normalizado y w_i su peso correspondiente.

Componente	Peso	Justificación
Actividad predicha	0,30	La inhibición de EGFR es el objetivo principal del proyecto.
ADMET blando	0,20	Evita priorizar moléculas con perfil farmacocinético desfavorable.
ADMET duro	0,10	Penaliza riesgos críticos de toxicidad, alertas o baja absorción.
Similitud al training	0,15	Equilibra novedad estructural y dominio de aplicabilidad del modelo QSAR.
QED	0,15	Representa calidad molecular global tipo <i>drug-like</i> .
Regla de Lipinski	0,10	Controla propiedades fisicoquímicas básicas.

Cuadro 3.6: Pesos utilizados para el cálculo de `reward_score`.

El `reward_score` no se utilizó como único criterio de selección, sino como herramienta auxiliar de ordenación dentro del conjunto de soluciones no dominadas. Esta diferencia es importante: una suma ponderada puede introducir arbitrariedad, mientras que Pareto permite conservar soluciones con distintos compromisos entre objetivos [4].

3.10. Pool elegible y selección mediante Pareto

3.10.1. Definición del conjunto elegible

Antes de aplicar Pareto se definió un conjunto de moléculas elegibles. Esta etapa evita que el frente de Pareto conserve moléculas formalmente no dominadas pero estratégicamente débiles, por ejemplo moléculas con baja actividad predicha o con múltiples alertas ADMET.

Los criterios mínimos fueron:

- superar el filtro químico básico;
- no ser coincidencia exacta con el conjunto de entrenamiento;
- no ser casi copia del conjunto de entrenamiento, definida como $Tanimoto \geq 0,95$;
- presentar similitud mínima al training de 0,30, como control aproximado de dominio de aplicabilidad;
- tener pIC_{50} predicha igual o superior a 6,0;
- superar al menos el 75 % de los filtros ADMET duros.

Tras aplicar estos criterios, el conjunto pasó de 8.241 moléculas con scoring completo a 2.133 moléculas elegibles, equivalente al 25,88 %.

3.10.2. Objetivos de Pareto

La selección multiobjetivo se aplicó sobre el conjunto elegible. Se consideraron seis objetivos, todos formulados como maximización:

- `predicted_pIC50`;
- `score_admet`;
- `score_admet_hard`;
- `score_training_similarity`;
- `score_qed`;
- `score_ro5`.

Una molécula se consideró no dominada si ninguna otra molécula del conjunto elegible era igual o mejor en todos los objetivos y estrictamente mejor en al menos uno. Esta estrategia es adecuada para diseño molecular temprano, ya que no obliga a elegir un único criterio dominante y permite conservar moléculas con perfiles de compromiso diferentes.

La aplicación de Pareto redujo las 2.133 moléculas elegibles a 37 moléculas no dominadas. Posteriormente, se ordenaron por `reward_score` y se aplicó un control de diversidad por scaffold de Murcko, limitando la presencia de un mismo scaffold a un máximo de tres moléculas. El resultado final fue una shortlist de 30 candidatas.

3.11. Comparación con inhibidores EGFR aprobados o de referencia

Como análisis complementario, se calculó la similitud máxima de las 30 candidatas finales frente a un conjunto de inhibidores EGFR aprobados o de referencia almacenado en `fda_ema_egfr_reference.csv`. Esta comparación no se utilizó para demostrar eficacia, sino para identificar si alguna molécula seleccionada era un análogo demasiado obvio de un compuesto conocido.

Las categorías de similitud se definieron como:

- $Tanimoto \geq 0,90$: casi clon de aprobado;
- $0,70 \leq Tanimoto < 0,90$: análogo cercano de aprobado;
- $0,40 \leq Tanimoto < 0,70$: relacionado medicinalmente;
- $Tanimoto < 0,40$: novedad alta frente a aprobados.

Este análisis se incorporó como criterio interpretativo, no como restricción de optimización. Una molécula cercana a fármacos conocidos puede ser menos novedosa, pero también puede encontrarse en una región química con mayor plausibilidad farmacológica.

3.12. Exportación, trazabilidad y productos obtenidos

La pipeline exportó todos los resultados de manera estructurada para facilitar auditoría y reproducibilidad. Los archivos se organizaron en cuatro carpetas:

- `outputs/mrl/`: checkpoints, histórico de fine-tuning y moléculas generadas;
- `outputs/scoring/intermediate/`: descriptores, filtros, predicciones ADMET, moléculas con scoring completo, elegibles y Pareto;
- `outputs/scoring/models/`: modelo QSAR entrenado y métricas de validación;
- `outputs/scoring/final/`: selección final de candidatas;
- `outputs/scoring/reports/`: resumen estructurado de ejecución.

Etapas	Número de moléculas
Moléculas generadas válidas y únicas	9.068
Moléculas tras filtro químico básico	8.241
Moléculas con scoring completo	8.241
Moléculas elegibles	2.133
Moléculas del frente de Pareto	37
Shortlist final	30

Cuadro 3.7: Reducción progresiva del conjunto molecular durante la pipeline.

El archivo principal resultante fue `shortlist30_final_candidates.csv`. Este archivo contiene, para cada candidata, la estructura SMILES, actividad predicha, scores ADMET, similitud frente al conjunto de entrenamiento, similitud frente a inhibidores EGFR de referencia, QED, violaciones de Lipinski, descriptores fisicoquímicos y scaffold de Murcko.

3.13. Limitaciones metodológicas

La metodología presenta limitaciones importantes que deben ser consideradas al interpretar los resultados. En primer lugar, la actividad frente a EGFR se estima mediante un modelo QSAR entrenado con datos previos, por lo que representa una señal *proxy* y no una medida experimental. En segundo lugar, las predicciones ADMET proceden de modelos computacionales y no sustituyen ensayos *in vitro* o *in vivo*. En tercer lugar, la pipeline no incluye docking molecular ni validación estructural explícita frente al bolsillo de unión de EGFR. Finalmente, el modelo generativo utilizado no es condicional, por lo que la optimización no ocurre durante la generación, sino en la fase posterior de scoring y selección.

Estas limitaciones no invalidan el enfoque, pero delimitan correctamente su alcance. El resultado debe interpretarse como una arquitectura de priorización temprana para explorar el espacio químico y seleccionar moléculas prometedoras para análisis posteriores, no como una validación farmacológica definitiva.

Capítulo 4

Resultados

Detallad en este apartado los resultados obtenidos utilizando la metodología descrita en el apartado anterior.

Las figuras tienen que estar explicadas y citadas en el texto, como la 4.1, en la cual se muestra el error en función de la distancia, en unidades arbitrarias. En todas las gráficas tiene que haber el título de los ejes.




Figura 4.1: Error en función de la distancia en unidades arbitrarias.

Capítulo 5

Conclusiones y trabajos futuros

Este capítulo tiene que incluir:

- Una descripción de las conclusiones del trabajo:
 - Una vez se han obtenido los resultados, ¿qué conclusiones se extraen?
 - ¿Estos resultados son los esperados? ¿O han sido sorprendentes? ¿Por qué?
- Una reflexión crítica sobre el logro de los objetivos planteados inicialmente:
 - ¿Hemos logrado todos los objetivos? Si la respuesta es negativa, ¿por qué motivo?
- Un análisis crítico del seguimiento de la planificación y metodología a lo largo del producto:
 - ¿Se ha seguido la planificación?
 - ¿La metodología prevista ha sido suficientemente adecuada?
 - ¿Ha habido que introducir cambios para garantizar el éxito del trabajo? ¿Por qué?
- De los impactos previstos en 1.3, ético-sociales, de sostenibilidad y de diversidad, evaluar/mencionar si se han mitigado (si eran negativos) o si se han conseguido (si eran positivos).
- Si han aparecido impactos no previstos a 1.3, evaluar/mencionar cómo se han mitigado (si eran negativos) o que han aportado (si eran positivos).
- Las líneas de trabajo futuro que no se han podido explorar en este trabajo y han quedado pendientes.

Capítulo 6

Glosario

Definición de los términos y acrónimos más relevantes utilizados dentro de la Memoria.

Capítulo 7

Bibliografía

1. Kattuparambil, A. A., Chaurasia, D. K., Shekhar, S., Srinivasan, A., Mondal, S., Aduri, R., and Jayaram, B. “Exploring chemical space for “drug-like” small molecules in the age of AI,” *Frontiers in Molecular Biosciences*, vol. 12, p. 1553667, 2025. doi: 10.3389/fmolb.2025.1553667.
2. Zhang, Z., Bian, Y., Xie, A., Han, P., and Zhou, S. “Can pretrained models really learn better molecular representations for AI-aided drug discovery?,” *Journal of Chemical Information and Modeling*, vol. 64, no. 7, pp. 2921–2930, 2024. doi: 10.1021/acs.jcim.3c0170.
3. Swanson, K., Walther, P., Leitz, J., Mukherjee, S., Wu, J. C., Shivnaraine, R. V., and Zou, J. “ADMET-AI: A machine learning ADMET platform for evaluation of large-scale chemical libraries,” *Bioinformatics*, vol. 40, no. 7, p. btae416, 2024. doi: 10.1093/bioinformatics/btae416.
4. Angelo, J. S., Guedes, I. A., Barbosa, H. J. C., and Dardenne, L. E. “Multi- and many-objective optimization: Present and future in *de novo* drug design,” *Frontiers in Chemistry*, vol. 11, p. 1288626, 2023. doi: 10.3389/fchem.2023.1288626.
5. Nada, H., Gul, A. R., Elkamhawy, A., Kim, S., Kim, M., Choi, Y., Park, T. J., and Lee, K. “Machine learning-based approach to developing potent EGFR inhibitors for breast cancer—Design, synthesis, and *in vitro* evaluation,” *ACS Omega*, vol. 8, no. 35, pp. 31784–31800, 2023. doi: 10.1021/acsomega.3c02799.
6. Valverde, C. *Pocket-Aware Molecular Generation Through Learned Protein Representations*. Master’s Thesis, Facultat de Matemàtiques i Informàtica, Universitat de Barcelona, 2025.
7. VeriSIM Life. “How AI assists small molecule drug design and development,” Resources, VeriSIM Life, 2024.
8. Niazi, S. K. “Artificial intelligence in small-molecule drug discovery: A critical review of methods, applications, and real-world outcomes,” *Pharmaceuticals*, vol. 18, p. 1271, 2025. doi: 10.3390/ph18091271.
9. Oliveira, R. I., Pereira, T. O., Abbasi, M., Salvador, J. A. R., and Arrais, J. P. “Deep learning for small-molecule drug discovery: From molecular design to clinical translation,” *Journal of Pharmaceutical Analysis*, 2025. doi: 10.1016/j.jpha.2025.101533.

10. Abdel-Rehim, A., Soldatova, L. N., and King, R. D. “A case study of the application of AI to early-stage drug discovery,” *Scientific Reports*, 2025. doi: 10.1038/s41598-025-32805-1.
11. Pham, P., Viet Thanh Duy, N., Cho, K. H., and Hy, T. S. “Generative AI-assisted virtual screening pipeline for generalizable and efficient drug repurposing,” Technical Report, 2025.
12. Sutanto, H., and Fetarayani, D. “Integrating artificial intelligence into small molecule development for precision cancer immunomodulation therapy,” *npj Precision Oncology*, 2025. doi: 10.1038/s44386-025-00029-y.
13. Xia, Y., Wu, K., Deng, P., Liu, R., Zhang, Y., Guo, H., Cui, Y., Pei, Q., Wu, L., Xie, S., Chen, S., Lu, X., Hu, S., Wu, J., Chan, C.-K., Chen, S., Zhou, L., Yu, N., Liu, H., Guo, J., Qin, T., and Liu, T.-Y. “Target-aware molecule generation for drug design using a chemical language model,” Technical Report, 2025.

Listado de apartados que son demasiado extensos para incluir dentro de la memoria y tienen un carácter autocontenido (por ejemplo, manuales de usuario, manuales de instalación, etc.)
Dependiendo del tipo de trabajo, es posible que no haya que añadir algún anexo.